

Relatório - Trabalho Final ICD

Análise Preditiva de Notificações de Dengue no Brasil

Alunos: Guilherme K. Trajanoski e Jean R. G. Wojcik

GUARAPUAVA

2026

1. Introdução

Este relatório apresenta o desenvolvimento de um estudo de Ciência de Dados aplicado às notificações de dengue no Brasil. O trabalho teve como objetivo utilizar dados reais de saúde pública para construir uma análise preditiva envolvendo quatro modelos supervisionados: KNN, Regressão Linear Simples, Regressão Linear Múltipla e Regressão Logística.

A dengue é uma arbovirose de notificação compulsória e constitui um problema recorrente de saúde pública no país. A base analisada reúne informações demográficas, clínicas e epidemiológicas de casos notificados, o que permite discutir aspectos relevantes da análise de dados, como seleção de variáveis, tratamento de valores ausentes, desbalanceamento de classes, avaliação de modelos e interpretação de resultados.

Além da aplicação dos modelos, o trabalho buscou comparar o desempenho das abordagens utilizadas e refletir sobre suas limitações. Dessa forma, o estudo não se restringe à obtenção de métricas, mas também considera a adequação dos métodos ao tipo de dado analisado e ao contexto epidemiológico.

2. Base de Dados

A base de dados utilizada foi obtida a partir do conjunto público de notificações de dengue disponibilizado pelo Sistema de Informação de Agravos de Notificação (SINAN), vinculado ao DATASUS. Foram considerados registros de diferentes anos, abrangendo um volume expressivo de notificações realizadas no Brasil.

Os dados contêm variáveis relacionadas à identificação temporal e geográfica da notificação, características demográficas dos pacientes, sintomas informados, comorbidades, classificação final, hospitalização e evolução do caso. Após a carga e organização dos dados, a base consolidada possuía aproximadamente 17,4 milhões de registros válidos para análise.

Por se tratar de uma base extensa e heterogênea, foi necessário adotar procedimentos de seleção e preparação dos dados antes da aplicação dos modelos. Essa etapa foi importante para reduzir ruídos, padronizar informações e tornar a modelagem computacionalmente viável.

3. Metodologia

3.1 Coleta e organização dos dados

A obtenção dos dados foi estruturada de forma automatizada, com verificação de disponibilidade dos arquivos e atualização apenas quando necessário. Essa estratégia permitiu manter a base organizada no ambiente de análise e reduziu obtenções repetidas de dados.

Após a obtenção dos arquivos, os dados foram consolidados em uma base relacional, facilitando consultas, filtragens, agregações temporais e seleção de amostras para os modelos de aprendizado supervisionado.

3.2 Limpeza e pré-processamento

Na etapa de pré-processamento, foram selecionadas apenas as variáveis consideradas relevantes para a análise epidemiológica e preditiva. As colunas mantidas foram agrupadas em categorias como informações temporais, localização, características demográficas, sintomas, comorbidades e desfechos clínicos.

Também foram tratados aspectos de codificação dos arquivos, conversão de datas, padronização de campos e remoção de registros sem informação essencial de notificação. Esses procedimentos foram necessários para reduzir inconsistências e permitir que os dados fossem utilizados de forma adequada pelos modelos.

Para evitar limitações de memória durante a modelagem, foram adotadas duas estratégias principais: amostragem para tarefas de classificação e agregação mensal para tarefas de regressão. Com isso, foi possível preservar a representatividade da base sem comprometer a execução dos experimentos.

3.3 Análise exploratória

A análise exploratória teve como finalidade compreender a distribuição geral dos dados antes da modelagem. Foram avaliadas a evolução temporal das notificações e a distribuição dos casos por sexo, além de informações relacionadas à hospitalização e localização geográfica.

Os gráficos gerados auxiliaram na interpretação inicial da base, permitindo observar padrões temporais, variações regionais e possíveis diferenças na composição dos registros. Essa etapa também serviu como apoio para a escolha das variáveis utilizadas nos modelos.

3.4 Modelagem preditiva

Foram aplicados quatro modelos supervisionados, contemplando tarefas de classificação e regressão. Para a classificação, o objetivo foi prever a ocorrência de hospitalização a partir de variáveis demográficas, sintomas e comorbidades. Para a regressão, o objetivo foi analisar a previsão do total mensal de casos notificados.

Os dados foram separados em conjuntos de treino e teste, permitindo avaliar a capacidade de generalização dos modelos. As métricas utilizadas foram escolhidas conforme o tipo de problema: para classificação, foram consideradas acurácia, precisão, recall, F1 e AUC; para regressão, foram utilizadas R^2 , erro absoluto médio e raiz do erro quadrático médio.

4. Modelos Aplicados

4.1 KNN

O modelo KNN foi utilizado para a tarefa de classificação da hospitalização. Essa técnica classifica uma observação com base na proximidade em relação aos exemplos do conjunto de treinamento. Por esse motivo, é sensível à escala das variáveis e ao aumento da dimensionalidade dos dados.

No contexto deste trabalho, o KNN serviu como uma abordagem comparativa para avaliar o comportamento de um método baseado em distância em uma base tabular com variáveis clínicas, demográficas e geográficas. O melhor ajuste obtido utilizou k igual a 5 e ponderação por distância.

4.2 Regressão Logística

A Regressão Logística também foi aplicada à classificação da hospitalização. Diferentemente do KNN, esse modelo estima a probabilidade de pertencimento a uma classe, sendo adequado para problemas binários.

A aplicação da Regressão Logística permitiu analisar a separabilidade dos casos hospitalizados e não hospitalizados a partir das variáveis disponíveis. O modelo apresentou desempenho superior ao KNN nas métricas principais de classificação, especialmente em termos de F1, recall e AUC.

4.3 Regressão Linear Simples

A Regressão Linear Simples foi utilizada como modelo de referência para previsão do total mensal de casos a partir de uma tendência temporal. O objetivo foi verificar até que ponto uma relação linear simples conseguiria explicar a variação das notificações ao longo do tempo.

Os resultados indicaram capacidade preditiva limitada, o que era esperado, pois a dinâmica da dengue envolve sazonalidade, surtos locais e fatores ambientais que não são plenamente representados por uma tendência linear simples.

4.4 Regressão Linear Múltipla

A Regressão Linear Múltipla ampliou a abordagem anterior ao considerar mais de uma variável explicativa. Foram utilizadas informações agregadas por período e localidade, incluindo características médias dos casos, proporções de sintomas e variáveis geográficas.

Esse modelo permitiu captar parte da variação associada a diferenças regionais e sazonais. Ainda assim, os resultados permaneceram limitados, reforçando que a previsão de casos de dengue depende de fatores externos não presentes na base analisada.

5. Resultados e Discussão

Os resultados obtidos permitem comparar o comportamento dos modelos de classificação e regressão. Na tarefa de classificação da hospitalização, a Regressão Logística apresentou desempenho mais equilibrado que o KNN. Embora o KNN tenha obtido maior acurácia, sua capacidade de identificar corretamente os casos positivos foi menor, conforme indicado pelo recall e pelo F1.

A Tabela 1 apresenta as métricas dos modelos de classificação. A Regressão Logística obteve AUC de 0,7257 e F1 de 0,4995, valores superiores aos do KNN, que alcançou AUC de 0,6747 e F1 de 0,3605. Esse resultado indica melhor capacidade geral de separação entre casos hospitalizados e não hospitalizados.

Tabela 1 - Métricas dos modelos de classificação da hospitalização

Modelo	Acurácia	Precisão	Recall	F1	AUC
KNN (k=5, distância)	0,7392	0,4655	0,2942	0,3605	0,6747
Regressão Logística	0,6844	0,4138	0,6301	0,4995	0,7257

A maior acurácia do KNN deve ser interpretada com cautela, pois a acurácia pode ser influenciada pelo desbalanceamento das classes. Em problemas de saúde pública, o recall é uma medida particularmente relevante, pois representa a proporção de casos positivos corretamente identificados. Nesse aspecto, a Regressão Logística foi mais adequada, com recall de 0,6301, enquanto o KNN obteve 0,2942.

Nas tarefas de regressão, os resultados indicaram baixo poder explicativo para a previsão do total mensal de notificações. A Regressão Linear Simples apresentou R^2 de 0,0018, mostrando que a tendência temporal isolada praticamente não explicou a variação observada. A Regressão Linear Múltipla apresentou melhora, com R^2 de 0,1701 e R^2 ajustado de 0,1264, mas ainda com desempenho limitado.

Tabela 2 - Métricas dos modelos de regressão

Modelo	R^2	R^2 ajustado	MAE	RMSE
Regressão Linear Simples	0,0018	-	8.591,88	38.357,72
Regressão Linear Múltipla (OLS)	0,1701	0,1264	8.153,92	30.811,21
Regressão Ridge	0,1693	-	-	-

A redução do erro na Regressão Linear Múltipla sugere que a inclusão de variáveis agregadas contribuiu para melhorar a previsão em relação ao modelo simples. Ainda assim, os valores de R^2 indicam que grande parte da variabilidade dos casos mensais permanece sem explicação. Isso reforça a importância de fatores externos, como clima, densidade populacional, circulação viral e ações de controle epidemiológico.

De modo geral, os resultados indicam que a escolha do modelo deve considerar tanto as métricas obtidas quanto a natureza do problema. Para a classificação de hospitalização, a Regressão Logística mostrou melhor equilíbrio entre sensibilidade e capacidade de separação. Para a previsão de casos mensais, os modelos lineares foram úteis como referência inicial, mas insuficientes para representar toda a complexidade epidemiológica da dengue.

Tabela 3 - Síntese comparativa dos modelos aplicados

Modelo	Finalidade	Síntese dos resultados
KNN	Classificação de hospitalização	Maior acurácia, mas menor recall e F1. Teve dificuldade para identificar casos positivos.
Regressão Logística	Classificação de hospitalização	Melhor desempenho geral entre os classificadores, com maior recall, F1 e AUC.
Regressão Linear Simples	Previsão de casos mensais	Funcionou como referência, mas apresentou baixo poder explicativo.
Regressão Linear Múltipla	Previsão de casos mensais	Melhorou a previsão em relação ao modelo simples, mas continuou limitada.

6. Limitações

A primeira limitação do estudo está relacionada à própria base de dados. Embora o SINAN contenha informações relevantes sobre os casos notificados, ele não inclui variáveis ambientais e socioeconômicas que influenciam diretamente a transmissão da dengue, como chuva, temperatura, densidade populacional e índices de infestação vetorial.

Outra limitação refere-se ao desbalanceamento das classes no problema de hospitalização. Em contextos de saúde pública, a interpretação das métricas deve considerar que falsos negativos podem ser mais críticos do que falsos positivos, já que a identificação de casos potencialmente graves é uma prioridade.

Também deve ser considerado que a utilização de amostras e agregações, embora necessária para viabilizar a execução dos experimentos, reduz parte da granularidade presente na base original. Portanto, os resultados devem ser interpretados como uma demonstração metodológica, e não como um modelo final para uso operacional em saúde pública.

7. Considerações Finais

O trabalho atingiu seu objetivo ao aplicar quatro modelos supervisionados a uma base real de notificações de dengue no Brasil. Foram realizadas etapas de coleta, organização, limpeza, análise exploratória, modelagem e comparação de resultados, compondo um fluxo completo de Ciência de Dados.

A Regressão Logística apresentou melhor desempenho entre os modelos de classificação, superando o KNN nas principais métricas de sensibilidade e separação entre classes. Já as

regressões lineares demonstraram utilidade como modelos de referência, mas também evidenciaram a complexidade da previsão de casos de dengue.

Como continuidade, seria recomendável incorporar variáveis climáticas, populacionais e ambientais, além de avaliar modelos mais adequados para séries temporais e dados epidemiológicos. Essa ampliação poderia melhorar a capacidade preditiva e tornar a análise mais próxima de aplicações práticas em vigilância em saúde.