

Análise de Casos de Dengue no Brasil

Classificação de hospitalização e regressão do atraso de notificação

Disciplina: Introdução à Ciência de Dados

Alunos: Guilherme K. Trajanoski e Jean R. G. Wojcik

Dados: SINAN DENGUE

Anos: 2024 e 2025

1 Resumo

Este trabalho aplica técnicas de ciência de dados a registros de dengue no Brasil, com dois focos principais: prever a hospitalização de pacientes e analisar o atraso entre o início dos sintomas e a notificação do caso.

Foram utilizados 8.202.583 registros dos anos 2024 e 2025. Para os modelos de classificação, foi extraída uma amostra balanceada de 120.000 registros, sendo 30.000 hospitalizados e 90.000 não hospitalizados.

Na classificação, a regressão logística apresentou AUC de 0,7407 e F1-score de 0,5123, superando o KNN em recall e robustez geral. Na regressão, o melhor resultado foi obtido com o modelo Ridge agregado por UF e semana epidemiológica, atingindo R^2 de 0,5121 e erro médio absoluto inferior a um dia.

2 Base de Dados e Pré-processamento

Os dados utilizados são provenientes do Sistema de Informação de Agravos de Notificação (SINAN), disponibilizados pelo Ministério da Saúde. Foram filtrados registros dos anos 2024 e 2025 referentes a dengue.

2.1 Variáveis utilizadas

As principais variáveis empregadas nos modelos foram:

- **Demográficas:** idade, sexo, raça/cor, escolaridade, gestante.
- **Territoriais:** UF de residência e UF de notificação.
- **Clínicas:** febre, mialgia, cefaleia, exantema, vômito, náusea, dor nas costas, conjuntivite, artrite, artralgia, petéquias, leucopenia, prova do laço, dor retroorbital.
- **Comorbidades:** diabetes, doenças hematológicas, hepatopatias, doença renal, hipertensão, doença ácido-péptica, doenças autoimunes.
- **Alvo de classificação:** hospitalização.

2.2 Tratamento

As datas foram convertidas para o formato padrão. Foi calculado o campo `dias_ate_notificacao` como a diferença entre a data de notificação e a data dos primeiros sintomas. Para as regressões, foram mantidos apenas registros com atraso entre 0 e 60 dias.

As variáveis categóricas foram codificadas com One-Hot Encoding. As variáveis numéricas foram padronizadas com `StandardScaler` quando utilizadas em modelos lineares. A variável alvo de classificação (`hospitaliz`) foi binarizada como 0 (não hospitalizado) e 1 (hospitalizado).

3 Análise Exploratória

A base completa contém 8.202.583 registros. Os principais achados descritivos foram:

- Idade média: 36,2 anos.
- Distribuição por sexo: 54,49% feminino, 45,37% masculino, 0,13% ignorado.
- Principais UFs: SP, MG, PR, GO, SC, RJ, RS, DF, BA, ES.
- Total de semanas epidemiológicas distintas: 105.




Figura 1: Evolução mensal dos casos de dengue.

Distribuição de casos por sexo (medida: percentual e contagem)




Figura 2: Distribuição dos casos por sexo.

4 Modelos de Classificação

O objetivo dos modelos de classificação foi prever se o paciente foi hospitalizado. Foram avaliados dois modelos: KNN e Regressão Logística. A base de treinamento continha 84.000 registros e a base de teste 36.000 registros.

4.1 KNN

O KNN foi ajustado com busca de hiperparâmetros por validação cruzada (3 folds), variando k em $\{5, 9, 15\}$ e o critério de pesos entre **uniform** e **distance**.

A melhor configuração foi $k = 5$ com **weights = distance**, obtendo F1 médio de validação cruzada de 0,3651. As métricas no conjunto de teste foram:

Métrica	Valor
Acurácia	0,7489
Precisão	0,4963
Recall	0,3059
F1-score	0,3785
AUC	0,6708

Tabela 1: Métricas do KNN no conjunto de teste.

O modelo classifica corretamente a maioria dos não hospitalizados, porém apresenta recall baixo, perdendo aproximadamente 70% dos hospitalizados.




Figura 3: Desempenho do KNN por valor de k .




Figura 4: Matriz de confusão do KNN.




Figura 5: Projeção PCA das features com coloração por classe real.




Figura 6: Taxa real e prevista de hospitalização por região.




Figura 7: Mapa da taxa prevista de hospitalização pelo KNN.




Figura 8: Erro absoluto entre taxa real e prevista por UF.

4.2 Regressão Logística

A Regressão Logística foi treinada com `class_weight = balanced` para lidar com o desbalanceamento entre classes, e `max_iter = 1000`.

Métrica	Valor
Acurácia	0,6907
Precisão	0,4228
Recall	0,6499
F1-score	0,5123
AUC	0,7407

Tabela 2: Métricas da regressão logística no conjunto de teste.

A regressão logística apresenta recall substancialmente maior que o KNN (0,6499 contra 0,3059), identificando corretamente 65% dos hospitalizados.




Figura 9: Matriz de confusão da regressão logística.




Figura 10: Curva ROC da regressão logística.




Figura 11: Distribuição das probabilidades previstas por classe real.




Figura 12: Fronteira de decisão da regressão logística no limiar de 0,5.




Figura 13: Curva sigmoide da função logística.




Figura 14: Métricas da regressão logística.




Figura 15: Principais coeficientes da regressão logística.

4.3 Comparação KNN versus Regressão Logística

Modelo	Acurácia	Precisão	Recall	F1-score	AUC
KNN (k=5, distance)	0,7489	0,4963	0,3059	0,3785	0,6708
Regressão Logística	0,6907	0,4228	0,6499	0,5123	0,7407

Tabela 3: Comparativo entre KNN e regressão logística.




Figura 16: Comparativo gráfico entre KNN e regressão logística.

A regressão logística vence em recall, F1-score e AUC, sendo mais adequada para uma aplicação de saúde pública, onde identificar corretamente os casos hospitalizados é prioritário.

5 Modelos de Regressão

O alvo dos modelos de regressão foi o atraso de notificação, definido como a diferença em dias entre a data de notificação e a data dos primeiros sintomas (`dias_ate_notificacao`). Este alvo é contínuo, interpretável epidemiologicamente e relevante para vigilância.

Foram avaliados quatro modelos: regressão linear simples, regressão linear múltipla, Ridge individual e Ridge agregado por UF e semana epidemiológica.

Os três primeiros foram aplicados no nível individual, com filtro de atraso entre 0 e 60 dias, resultando em 119.997 registros (83.997 treino e 36.000 teste). O quarto modelo foi aplicado no nível agregado.

5.1 Regressão Linear Simples

O modelo mais simples relaciona o atraso de notificação apenas com a idade do paciente:

$$\text{dias_ate_notificacao} = \beta_0 + \beta_1 \cdot \text{idade_anos}$$

Os resultados no conjunto de teste foram:

Métrica	Valor
R^2	0,0060
MAE	2,1069 dias
RMSE	3,1668 dias
Intercepto	2,8407
Coefficiente (idade)	0,0100

Tabela 4: Resultados da regressão linear simples.

Interpretação: a idade isoladamente praticamente não explica a variação no atraso de notificação. A cada 10 anos de idade, o atraso aumenta em média 0,1 dia, um efeito clinicamente irrelevante.




Figura 17: Regressão simples: idade versus atraso de notificação.




Figura 18: Regressão simples: valores reais e previstos.




Figura 19: Resíduos da regressão linear simples.

5.2 Regressão Linear Múltipla Individual

Foram adicionadas variáveis demográficas, territoriais, clínicas e de calendário:

- **Numéricas:** idade, dia da semana dos sintomas, indicador de fim de semana, seno e cosseno do mês.
- **Categóricas:** sexo, raça/cor, escolaridade, UF de residência, UF de notificação, mês.

- **Binárias:** febre, mialgia, cefaleia, vômito, náusea, diabetes, doença renal, hipertensão.

Métrica	Valor
R^2	0,0721
R^2 ajustado	0,0698
MAE	2,0396 dias
RMSE	3,0597 dias

Tabela 5: Resultados da regressão linear múltipla individual.

A inclusão de mais variáveis elevou o R^2 de 0,006 para 0,072, uma melhora significativa, mas ainda indicando que a maior parte da variação no atraso individual permanece não explicada.




Figura 20: Regressão múltipla: valores reais e previstos.




Figura 21: Resíduos da regressão linear múltipla.




Figura 22: Principais coeficientes da regressão múltipla.

5.3 Ridge Individual

A regressão Ridge aplica regularização L2 sobre os mesmos preditores da regressão múltipla, com o objetivo de reduzir a variância dos coeficientes.

Métrica	Valor
Melhor α	50
R^2	0,0725
MAE	2,0391 dias
RMSE	3,0591 dias

Tabela 6: Resultados do Ridge individual.

Os resultados são muito próximos aos da regressão linear múltipla, indicando que o modelo OLS já não sofria de alta instabilidade. O ganho com regularização foi marginal.




Figura 23: Ridge individual: evolução do R^2 com alpha.




Figura 24: Ridge individual: evolução do RMSE com alpha.




Figura 25: Ridge individual: norma dos coeficientes com alpha.

5.4 Ridge Agregado por UF e Semana

Dado o baixo poder explicativo dos modelos individuais, a última estratégia foi modelar o atraso médio de notificação agregado por UF de notificação e semana epidemiológica. Foram obtidos 211 grupos, sendo 147 para treino e 64 para teste.

As variáveis preditoras foram: total de casos, idade média, percentual de hospitalização, percentuais de sintomas, sazonalidade senoidal semanal e UF de notificação.

Métrica	Valor
Melhor α	1
R^2	0,5121
MAE	0,8399 dias
RMSE	1,2543 dias

Tabela 7: Resultados do Ridge agregado UF/semana.

Este modelo apresentou o melhor desempenho entre todos os modelos de regressão, explicando cerca de 51% da variação do atraso médio e com erro médio inferior a um dia.




Figura 26: Ridge agregado UF/semana: valores reais e previstos.

5.5 Comparação dos Modelos de Regressão

Modelo	R^2	MAE (dias)	RMSE (dias)
Linear simples individual	0,0060	2,1069	3,1668
Linear múltipla individual	0,0721	2,0396	3,0597
Ridge individual	0,0725	2,0391	3,0591
Ridge agregado UF/semana	0,5121	0,8399	1,2543

Tabela 8: Comparativo dos modelos de regressão para atraso de notificação.




Figura 27: Comparativo gráfico dos modelos de regressão.

6 Discussão

Os resultados revelam naturezas distintas entre os problemas de classificação e regressão abordados.

Na classificação, a regressão logística mostrou-se mais adequada que o KNN para identificação de hospitalizações, especialmente por seu recall superior. Em uma aplicação de vigilância, detectar corretamente os casos hospitalizados – mesmo com algum falso positivo – é prioritário.

Na regressão, o baixo poder explicativo dos modelos individuais (R^2 máximo de 0,072) indica que o atraso de notificação depende mais de fatores contextuais do que de características clínicas ou demográficas individuais. A idade, por exemplo, apresentou associação praticamente nula com o atraso.

O modelo agregado por UF e semana epidemiológica, com R^2 de 0,5121 e erro médio inferior a um dia, demonstra que o atraso de notificação se torna muito mais previsível

quando analisado no nível territorial-temporal. Isso sugere que fatores administrativos, sazonais e regionais são os principais determinantes da velocidade de notificação.

7 Conclusão

Este trabalho aplicou modelos de classificação e regressão a uma base real de 8,2 milhões de registros de dengue do SINAN, restrita aos anos de 2024 e 2025.

Na classificação de hospitalização:

- A regressão logística superou o KNN em recall, F1-score e AUC.
- Com AUC de 0,7407 e recall de 0,6499, a regressão logística é mais adequada para triagem de casos graves.

Na regressão do atraso de notificação:

A idade isoladamente não explica o atraso ($R^2 = 0,006$).

A inclusão de múltiplas variáveis individuais elevou o R^2 para 0,072.

O modelo Ridge agregado por UF e semana foi o melhor, com R^2 de 0,5121 e erro médio inferior a um dia.

A principal conclusão é que a hospitalização pode ser parcialmente prevista por características individuais, enquanto o atraso de notificação é melhor compreendido em nível territorial e temporal, refletindo processos administrativos e regionais que transcendem o perfil clínico do paciente.